



UNIVERSIDAD DE SANTIAGO DE CHILE
DEPARTAMENTO DE MATEMÁTICA Y C.C.
Ingeniería Matemática
Ciencia de Datos para Datos Funcionales

Un estudio del avance del Dióxido de Carbono desde 1950 hasta 2024 a nivel global

Milena Rojas Sepúlveda, Exequiel de la Cuadra

14 de enero de 2026

Santiago - Chile

Índice general

1. Introducción	1
2. Estado del Arte	2
3. Marco Teórico	4
4. Implementación - Metodología	6
5. Interpretación de Resultados	8
5.1. Análisis FDA	8
5.1.1. Gráfico con base de funciones B-spline y Fourier	8
5.1.2. Gráfico de Media y Varianza	9
5.1.3. Análisis de Componentes Principales Funcio- nales (FPCA)	10
5.2. Clasificación	12
5.2.1. Gussian Mixture Model	12
5.2.2. Método K-means	13
5.2.3. Método DBSCAN	16
5.2.4. ST-DBSCAN	18
5.2.5. Análisis de países con mayor emisión a nivel histórico	19

6. Conclusión y Trabajos Futuros

25

Índice de figuras

4.1. Metodología de trabajo	6
5.1. Aproximaciones de las emisiones por país utilizando 30 funciones base B-Spline y Fourier	9
5.2. Media funcional usando B-pline	9
5.3. Media y Varianza funcional usando B-pline	10
5.4. Media y Varianza funcional con respecto a las emisiones de todos los países . . .	10
5.5. Componente principal 1	11
5.6. Componente principal 2	11
5.7. Clustering con leyenda asociada a cada grupo	12
5.8. Gráfico asociado a las curvas y a la media de emisión por cada clúster.	13
5.9. Gráfico de la media funcional por cada clúster.	13
5.10. Gráfico del método del codo para obtener k óptimo, en donde se utilizó $k = 2$ y $k = 4$	14
5.11. Gráfico de K-means con $k = 2$	14
5.12. Gráficos por cada clúster utilizando K-means $k = 2$	15
5.13. Gráfico de K-means con $k = 4$	15
5.14. Gráficos por cada clúster utilizando K-means $k = 4$	16
5.15. Gráfico de k-NN para obtener el valor <i>eps</i>	16
5.16. Gráfico que representa la clasificación de naciones mediante DBSCAN.	17
5.17. Gráfico que indica la curva de países por clúster mediante DBSCAN.	17
5.18. Mapa de distribución de países por clúster mediante ST-DBSCAN.	18
5.19. Gráfico de las emisiones totales de dióxido de carbono en la Antártica.	19
5.20. Gráfico de las emisiones totales de dióxido de carbono en Canadá y Estados Unidos. .	19
5.21. Gráfico que muestra los doce países con mayor emisión de CO_2	20
5.22. Gráfico que identifica las emisiones totales de China y Estados Unidos.	20
5.23. Gráfico que muestra las emisiones totales acumuladas de China y Estados Unidos (es decir, a medida que se avanza en los años, se suman las emisiones de cada año). .	21
5.24. Gráfico de las emisiones totales los países que se encuentran en el clúster 3 de k-means $k = 4$	21
5.25. Gráfico de emisiones totales acumuladas los países que se encuentran en el clúster 3 de k-means $k = 4$	22

- 5.26. Gráfico de emisiones totales los países que se encuentran en el clúster 4 de k-means $k = 4$ 23
- 5.27. Gráfico de las emisiones totales de los países que se encuentran en el clúster 4 de k-means $k = 4$, junto con con el gráfico de China (clúster 2) y Japón (clúster 3). 23

1. Introducción

En el presente trabajo se lleva a cabo un estudio del comportamiento espacio-temporal de las emisiones de dióxido de carbono (CO_2) desde el año 1950 hasta el año 2024. El análisis contempla la evolución de diversas fuentes emisoras, entre ellas: aceite, carbón, cemento, petróleo y quema de gases. A partir de las siguiente variables, se desarrollan comparaciones tanto globales como específicas entre diversos países, con el propósito de reconocer patrones comunes, identificar tendencias a largo plazo y examinar con hechos recientes la contribución de cada sector.

Asimismo, se aplican diferentes métodos de clasificación no supervisada, tales como K-means, DBSCAN y ST-DBSCAN, con el fin de organizar los países según la similitud de sus trayectorias de emisiones y obtener representaciones visuales que permitan interpretar los agrupamientos desde una perspectiva ambiental, económica y social. Las técnicas anteriores permiten detectar clústeres significativos, anomalías y patrones regionales a lo largo del tiempo.

Como marco de referencia técnico, se utiliza el artículo de Hobbs et al. (2024), el cual se orienta al uso de herramientas de Machine Learning para el estudio, previsión y mitigación de las emisiones globales. Si bien este estudio se centra en el análisis descriptivo y de agrupamiento, se plantea como una línea de trabajo futuro la incorporación de modelos paramétricos para el análisis estadístico funcional, tales como el ANOVA funcional. Dicho enfoque permitiría tasar diferencias entre grupos de países y verificar factores externos explicativos aprovechando la representación de las series mediante bases B-Spline y Fourier.

Por último, se hará uso del informe oficial asociado al conjunto de datos empleado en este estudio, ya que dicho documento proporciona información complementaria de carácter metodológico y contextual que permite comprender con mayor profundidad la construcción, alcance y limitaciones del *dataset* utilizado.

2. Estado del Arte

El calentamiento global es un gran desafío desde la perspectiva industrial, dado que el desarrollo de diversas herramientas tecnológicas ha permitido avances en el aspecto socioeconómico, la automatización y la mejora de la eficiencia laboral. Sin embargo, la predicción y análisis de las emisiones del dióxido de carbono (CO_2) se encuentran en un punto crítico, el cual es potenciado por la urgencia de abordar el cambio climático. Las investigaciones recientes se enfocan principalmente en dos áreas: la predicción de series de tiempo y factores socioeconómicos mediante técnicas de aprendizaje automático (Machine Learning), y el análisis estadístico avanzado de los flujos de carbono, orientado a comprender la dinámica atmosférica a escala global y regional Bhatt et al. (2023).

En el contexto de la predicción de emisiones y factores socioeconómicos mediante Aprendizaje Automático, se puede observar que diversos modelos entrenados estiman un aumento de la temperatura global de aproximadamente $5.6\text{ }^\circ\text{C}$ para el año 2047, y complementariamente se ha identificado un punto de no retorno dicho año. Los estudios también señalan que la población y la emisión de otros gases de efecto invernadero constituyen los factores más influyentes en la generación de emisiones de (CO_2). A esto se añaden variables altamente correlacionadas, que incluyen la industria del cemento y las industrias de combustión, entre ellas las del petróleo y del gas Bhatt et al. (2023). De manera adicional, en los 20 países que representan la mayor proporción de la población mundial, el consumo de energético y el crecimiento económico (PIB) se identifican como indicadores que promueven las emisiones de (CO_2) Mardani et al. (2020). En cuanto a las metodologías predictivas, se han implementado enfoques híbridos, modelos de conjunto y técnicas de reducción de dimensionalidad, principalmente integradas en esquemas de predicción multi-etapa.

Por otro lado, el uso de técnicas de Machine Learning para la captura y el análisis de flujos de carbono ha permitido estimar la incertidumbre asociada al flujo, y comprender los mecanismos involucrados en procesos de absorción. Para ello, se han empleado modelos de redes neuronales profundas (DNN) como herramientas de modelos generativos que han permitido correlacionar la capacidad de absorción de (CO_2) con diversas propiedades texturales de los materiales Zhang et al. (2019).

Asimismo, se ha empleado la metodología de Análisis Funcional de Varianza (fANOVA) para estudiar las estimaciones del incremento del flujo de carbono, permitiendo evaluar el im-

pacto de múltiples factores tales como el modelo de transporte atmosférico, la fuente de datos y el método de agregación. Entre los hallazgos más relevantes se encuentra un componente residual con marcada variabilidad mensual no explicada por los factores analizados, caracterizada por una coherencia espacial y temporal limitada. En contraste, la media general y el efecto del modelo de flujo presentan la mayor coherencia espacial entre los componente del análisis. Estos resultados consolidan a fANOVA como una herramienta eficaz para cuantificar la coherencia espacial y descomponer la variabilidad atribuible a los diversos factores involucrados en las estimaciones de flujo de carbono Hobbs et al. (2024).

3. Marco Teórico

Para el estudio este trabajo se sustenta en “The Global Carbon Project’s fossil (CO₂) emissions dataset: 2025 release”, cuyos autores son Robbie M. Andrew y Glen P. Peters. Los parámetros identificados se definen y categorizan de manera específica. Más aún, el estudio no se limita solo a la quema de combustibles, sino que también a las emisiones provenientes de la oxidación de combustibles fósiles y la descomposición de carbonatos fósiles. Lo cual incluye tanto la combustión para energía como los procesos químicos industriales que libera (CO₂).

En este caso, tenemos diversas categorías de estudio, y las usadas son las siguientes:

1. Tipo de Combustible y Fuente:

- Combustibles Sólidos: Principalmente compuesto de carbón.
- Combustibles Líquidos: Abarca petróleo y sus derivados. Los líquidos de gas natural se asignan en esta categoría.
- Combustibles Gaseosos: Aquí se encuentra el gas natural.
- Quema de gas (*Flaring*): Se contabiliza el (CO₂) emitido por la quema de gas natural no aprovecha en los sitios de extracción de petróleo y gas.
- Emisiones de Procesos:
 - Cemento: Se contabiliza las emisiones del proceso química de producción de cemento, no solo la energía usada para producirlo.
 - Otro Carbonatos: La producción de cal, la cuál está especialmente detallada para países como China y Estados Unidos, y el uso de carbonatos en la depuración de gases.

2. Parámetros Geográficos y Temporales:

- Continuidad Territorial: Se mantiene el estudio de series de tiempo continuas para las fronteras de los países actuales, desagregando entidades históricas para permitir el análisis a largo plazo.
- Per Cápita: Se incluye una serie de datos específica para las emisiones por persona, cruzando los datos de emisiones con estadísticas de población de la ONU y registros históricos.

Como se expuso en las secciones anteriores, a continuación se desarrollan las definiciones y conceptos asociados a los datos funcionales y sus componentes principales. Adicionalmente, se describen los modelos de clasificación seleccionados: Gaussian, K-means, DBSCAN y ST-DBSCAN, con el fin de destacar su relevancia para la identificación de patrones.

En el contexto de este informe, cada país es considerado como la unidad observacional principal y su representación como una función en el tiempo, se basa en los datos registrados del dióxido de carbono a partir de 1950. Para su estudio, las observaciones discretas se aproximan mediante combinaciones lineales de funciones base, tales como B-splines y bases de Fourier, lo que permite obtener curvas suaves y coherentes con la naturaleza de los datos.

En cuanto a los modelos de clasificación se detalla lo siguiente:

- Modelo de Mezcla Gaussiana (GMM): Cada componente gaussiana representa un clúster, y cada observación tiene una probabilidad asociada de pertenecer a cada uno de ellos. Este modelo utiliza el algoritmo de Esperanza-Maximización (EM) para estimar los parámetros de media, covarianza y mezcla. Puede modelar clústeres elípticos y manejar el solapamiento entre grupos mediante probabilidades.
- K-means: Es un algoritmo de particionamiento que divide un conjunto de n observaciones en k grupos disjuntos. El objetivo es minimizar la suma de los cuadrados dentro de cada grupo (inercia). Además, su algoritmo funciona de forma iterativa, es decir, selecciona los k centroides de forma aleatoria, luego asigna a cada observación el centroide más cercano, actualiza los centroides como el promedio de las observaciones asignadas, y vuelve a repetir el proceso.
- DBSCAN (Density-Based Spatial Clustering of Applications with Noise): Es un método de clustering basado en densidad, diseñado para identificar regiones densas en el espacio de datos y distinguir observaciones aisladas como ruido. Se basa en dos parámetros principales ϵ el cual es el radio de la vecindad, y MinPts. que son los puntos mínimos requeridos para formar una región densa. Acá se clasifican puntos núcleo, de frontera y ruido.
- ST-DBSCAN: Este es una extensión de DBSCAN diseñado para incorporar explícitamente información espacial y temporal en el proceso de clustering. Este algoritmo utiliza dos umbrales de distancia distintos y un valor de densidad.

4. Implementación - Metodología

La metodología a seguir se detalla en el siguiente diagrama.




Figura 4.1: Metodología de trabajo

La estructura anterior se desarrolla en diversas etapas, cuyo enfoque progresivo abarca desde el preprocesamiento de los datos hasta el análisis e interpretación de los resultados.

En primer lugar, el análisis preliminar de los datos incluye la corrección de los nombres de los países y la estandarización de las variables.

Posteriormente, en el entorno de programación de RStudio, se procede con la eliminación observaciones con valores faltantes (NA) y a la selección de variables de interés, las cuales corresponden al tiempo, expresado en años, y a las emisiones totales de dióxido de carbono de cada país. El espacio temporal abarca el período comprendido entre 1950 hasta 2024. En esta etapa, se efectuó un análisis preliminar por medio de la visualización gráfica de las emisiones totales

en el tiempo.

A continuación, las series temporales discretas fueron transformadas en representaciones funcionales, utilizando bases de Fourier y B-Spline con 30 funciones bases. Sobre las cuales se calcularon y analizaron la media funcional y la desviación estándar funcional, de modo que se estudia la tendencia promedio de las emisiones como la dispersión entre la diversidad de países a lo largo del tiempo.

Ahora bien, con el fin de reducir la dimensionalidad y obtener una mayor proporción de variabilidad entre los datos, se aplicó un Análisis de Componentes Principales Funcionales (FPCA). A partir del cual se determinó el número mínimo de componentes principales necesarias para explicar al menos el 95 % de la varianza total, y estos componentes fueron utilizados como variables de entrada para los métodos de clasificación.

En cuanto a los modelos de clasificación no supervisada. En primer lugar, se aplicó un Modelo de Mezcla Gaussiana (GMM) para identificar agrupamientos probabilísticos. De forma complementaria, se utiliza el algoritmo de K-means considerando una configuración con $k = 2$ y $k = 4$, lo que permitió analizar diferentes niveles de partición entre los países según sus patrones de emisión.

Para cada uno de los métodos de clasificación empleados, se calcularon y graficaron las curvas funcionales promedio por grupo. Posteriormente, se aplicaron los algoritmos DBSCAN y ST-DBSCAN, orientados a la detección de clústeres basados en densidad y la identificación de observaciones atípicas.

Finalmente, los resultados obtenidos mediante los distintos métodos permiten realizar un análisis de forma individual y conjunta, con el propósito de identificar patrones consistentes.

5. Interpretación de Resultados

Para realizar un análisis consistente, es importante señalar que las emisiones de dióxido de carbono tiene una unidad de medida de millones de toneladas (Mt).

5.1. Análisis FDA

A continuación se muestran los resultados observados.

5.1.1. Gráfico con base de funciones B-spline y Fourier

En la *figura 5.1* se observan las curvas aproximadas de las emisiones totales por año de cada país, obtenidas mediante la base B-spline y la base de Fourier. A simple vista, la aproximación basada en Fourier presenta un error significativo, lo cual es evidenciado en la aparición de un intervalo con emisiones negativas, suceso que no concuerda con los datos trabajados.

Es por ello, que se puede notar que el MSE de cada base es la siguiente:

- MSE B-spline: $6.229667e+13$
- MSE Fourier: $5.96723e+15$




Figura 5.1: Aproximaciones de las emisiones por país utilizando 30 funciones base B-Spline y Fourier

Con el resultado del error anterior, se deciden realizar los futuros análisis utilizando las funciones aproximadas con la base B-Spline.

5.1.2. Gráfico de Media y Varianza

El gráfico de las emisiones promedio por año *figura 5.2* exhibe el crecimiento generalizado de las emisiones totales. Del mismo modo, al considerar la varianza funcional *figura 5.3*, se deduce que las trayectorias de emisión de los países tienden a crecer y a alejarse de la media funcional.




Figura 5.2: Media funcional usando B-pline




Figura 5.3: Media y Varianza funcional usando B-pline

Por otro lado, al observar la media y la varianza funcional considerando a todos los países, como se expone en la *figura 5.4*, es evidente que la mayoría de las naciones se concentran en un intervalo *acotado* de emisiones. Sin embargo, existen países cuyas emisiones totales son significativamente superiores a la media, lo que se responde principalmente por el desbalance presente en los datos.




Figura 5.4: Media y Varianza funcional con respecto a las emisiones de todos los países

5.1.3. Análisis de Componentes Principales Funcionales (FPCA)

Mediante el análisis de la varianza acumulada, se observó que la representación funcional mediante B-Spline requiere solamente de dos componentes para que la varianza explicada sea mayor o igual al 95 %. Dado este resultado, se graficó la primera y la segunda componente principal, en donde ambas están centradas respecto de la media funcional, las cuales se muestran en *figura 5.5* y *figura 5.6*, respectivamente.




Figura 5.5: Componente principal 1

Este análisis permite descomponer la variabilidad de las emisiones en dos estructuras principales. Por un lado, la primera componente principal *figura 5.5*, representa la magnitud global de las emisiones. En este gráfico, la curva asociada a un puntaje positivo “+” se sitúa por sobre la media, mientras que la curva con puntaje negativo “−” se ubica por debajo de ella. En este contexto, los países con puntajes positivos corresponden a naciones con altos niveles de emisión de dióxido de carbono, mientras que aquellos con puntajes negativos representan países con emisiones relativamente bajas.

Por otro lado, la segunda componente principal *figura 5.6*, indica una variación asociada a la tendencia temporal de las emisiones, es decir, cambios en la velocidad o dirección del crecimiento. En particular, la curva con puntaje positivo “+” se mantiene por sobre la media funcional hasta aproximadamente el año 2006, para luego visualizar un descenso. En contraste, la curva con puntaje negativo “−” detalla el comportamiento opuesto. La interpretación de estos patrones sugiere que existen países que de forma inicial presentan niveles elevados de emisión, pero que a lo largo del tiempo han ido reduciendo su contaminación, mientras que otros países mostraron un crecimiento significativo en períodos recientes.




Figura 5.6: Componente principal 2

5.2. Clasificación

5.2.1. Gussian Mixture Model

A partir de las dos componentes principales previamente graficadas, se realizó el proceso de clustering mediante el modelo de mezcla gaussiana, cuyo resultado se puede visualizar en la siguiente *figura 5.7*.




Figura 5.7: Clustering con leyenda asociada a cada grupo

En esta figura se observa que los clústeres 1, 2 y 3 concentran la mayor cantidad de países (ver Anexo), mientras que el clúster 4 está compuesto solo por doce elementos, los cuales serán analizados de forma detallada posteriormente. De es último clúster se destaca que sus puntos se encuentran con mayor dispersión en el espacio de componentes principales, lo que sugiere una mayor heterogeneidad y un posible desbalance en los datos asociados a este grupo.

Posteriormente, como se observa en las curvas de clustering *figura 5.8*, los países que presentan mayores niveles de emisión corresponden al clúster 4. Esta diferencia se aprecia con detalle en la figura de medias funcionales por clúster *5.9*, donde las medias funcionales de los clústeres 1, 2 y 3 se mantiene relativamente cercanas entre sí, mientras que la media funcional del clúster 4 exhibe un crecimiento significativamente mayor a lo largo del tiempo.




Figura 5.8: Gráfico asociado a las curvas y a la media de emisión por cada clúster.




Figura 5.9: Gráfico de la media funcional por cada clúster.

En conjunto, estos gráficos indican que los países agrupados en el clúster 4 corresponden a las naciones con las mayores emisiones de dióxido de carbono a nivel global, diferenciándose de manera clara del resto de los grupos tanto en magnitud como en comportamiento.

5.2.2. Método K-means

Al aplicar el método del codo, se obtuvo la siguiente gráfica correspondiente *figura 5.10*. A partir de este gráfico, se elige el valor de k (eje horizontal) en el punto donde la curva deja de decrecer de manera abrupta.




Figura 5.10: Gráfico del método del codo para obtener k óptimo, en donde se utilizó $k = 2$ y $k = 4$.

En primer lugar, se realizó el proceso de clustering considerando $k = 2$. En este caso, el resultado mostrado *figura 5.11* evidencia la formación de dos grupos. A partir de este agrupamiento, se observa que el segundo clúster está compuesto exclusivamente por China y Estados Unidos, países que históricamente presentan los mayores niveles de emisión de dióxido de carbono. Asimismo, la media funcional de este grupo indica un crecimiento considerablemente mayor en comparación con la media funcional perteneciente al primer clúster, tal como se aprecia en la siguiente *figura 5.12*.




Figura 5.11: Gráfico de K-means con $k = 2$.




Figura 5.12: Gráficos por cada clúster utilizando K-means $k = 2$

Posteriormente, se llevó a cabo el clustering considerando $k = 4$, obteniéndose cuatro clústeres, tal como se muestran en la siguiente *figura 5.13*. En este marco, el clúster 2 continúa siendo conformado por China y Estados Unidos. Por su parte, el clúster 3 agrupa naciones como Alemania, India, Japón y Rusia. Además, el clúster 4 contiene 19 países, de las cuales se observan naciones como Francia, Canadá, Italia, Polonia, Reino Unido y Ucrania.

Es importante destacar que todos estos países coinciden en pertenecer al clúster 4 obtenido mediante el modelo de mezcla gaussiana, y adicionalmente, forman parte del conjunto de los doce países con mayores emisiones históricas de dióxido de carbono, lo que demuestra que existe una alta consistencia entre ambos enfoques de clasificación.




Figura 5.13: Gráfico de K-means con $k = 4$.

Finalmente, al graficar las curvas por clúster y trazar su respectiva media funcional como se observa en la *figura 5.14*, se identifica un patrón de crecimiento de las emisiones más pronunciado

en el clúster 2, seguido por los clústeres 3 y 4. En contraste, el clúster 1 no presenta un cambio significativo en comparación con los otros grupos, lo que sugiere un comportamiento estable en el tiempo.




Figura 5.14: Gráficos por cada clúster utilizando K-means $k = 4$.

5.2.3. Método DBSCAN

En esta sección se aborda la aplicación del método DBSCAN, considerando la selección del radio de vecindad ϵ a partir del gráfico de distancias k-NN, el cual se muestra en la siguiente *figura 5.15*. En este gráfico, el valor adecuado de ϵ se identifica en el punto donde la curva comienza a incrementarse de manera brusca, lo que indica un cambio significativo en la densidad de los datos. En este sentido, dicho valor debió ser elegido de forma aproximada, ya que no se obtuvo de forma automática.




Figura 5.15: Gráfico de k-NN para obtener el valor ϵ .

A partir de lo anterior, se realizó una búsqueda de los vecinos utilizando una esfera de radio $eps = 1,25 \cdot 10^9$, y una cantidad mínima de vecinos definida como $minPts = 4$. Este método genera dos grupos, tal como se observa en la *figura 5.16*. En particular, el grupo clasificado como “ruido”

A partir de lo anterior, la búsqueda de vecinos con una esfera de radio $eps = 1,25 \cdot 10^9$, y una cantidad mínima de vecinos por esfera dada por $minPts = 4$. Este método entrega dos grupos, tal como se muestra en la *figura 5.16*. En este caso, el grupo considerado como “ruido” está conformado por los siguiente países: China, Alemania, India, Japón, Rusia y Estados Unidos.




Figura 5.16: Gráfico que representa la clasificación de naciones mediante DBSCAN.

Los países identificados como “ruido” coinciden con ser los seis países mayores emisores de dióxido de carbono a nivel global. Además, se puede notar que estos países también aparecen en el clúster 4 del modelo de mezcla gaussiana, y en los clústeres 2 y 3 del método k-means cuando se considera $k = 4$.




Figura 5.17: Gráfico que indica la curva de países por clúster mediante DBSCAN.

Finalmente, al graficar las curvas de emisiones por clúster, como se muestra en siguiente

figura 5.17, se aprecia un mayor desbalance en los datos asociados al grupo de “ruido”. Este comportamiento confirma que dichos países presentan trayectorias de emisión significativamente distintas, caracterizadas por un crecimiento acelerado de las emisiones de dióxido de carbono en comparación al resto de naciones.

5.2.4. ST-DBSCAN

En un procedimiento análogo a DBSCAN, en ST-DBSCAN permitió identificar un valor óptimo aproximado para el radio de la vecindad. En este caso, los datos fueron previamente reescalados dividiendo las distancias del gráfico k-NN por 10^9 , lo que permite seleccionar el parámetro $eps = 1,25$. Del mismo modo, se mantuvo la cantidad de mínima de vecinos usada con anterioridad, la cual fue fijada en $minPts = 4$. Con estos parámetros, el algoritmo identifica como pertenecientes al grupo de “ruido” a las siguientes naciones: Antártica, Canadá, China, India, Japón, Rusia y Estados Unidos, cuya distribución son presentados en la siguiente figura 5.18.




Figura 5.18: Mapa de distribución de países por clúster mediante ST-DBSCAN.

En esta clasificación, resulta relevante analizar dos países que no han sido identificados como “ruido” en el método anterior: la Antártica y Canadá. Por un lado, la Antártica es clasificada como “ruido” debido a sus niveles extremadamente bajos de emisión de dióxido de carbono, lo cual se evidencia en la figura 5.19. Este comportamiento contrasta de forma evidente con las emisiones visualizadas en países como Canadá, Rusia o Alemania. Adicionalmente, sus vecinos geográficos más cercanos, tales como Chile, Argentina, Sudáfrica y Nueva Zelanda, se encuentran separados por grandes distancias, por ende, se refuerza su clasificación como *outlier*.




Figura 5.19: Gráfico de las emisiones totales de dióxido de carbono en la Antártica.

Por otra parte, Canadá es identificado como “ruido” debido a la influencia de su vecino más cercano, Estados Unidos. Al considerar de forma conjunta los factores demográficos, el nivel total de emisiones y su crecimiento en el tiempo, como se muestra en la *figura 5.20*, se concluye que Canadá presenta un comportamiento atípico en comparación con los países analizados con anterioridad.




Figura 5.20: Gráfico de las emisiones totales de dióxido de carbono en Canadá y Estados Unidos.

5.2.5. Análisis de países con mayor emisión a nivel histórico

Es importante recordar que los doce países con mayores emisiones históricas de dióxido de carbono corresponden a aquellos presentados en la *figura 5.21*. Este conjunto coincide exactamente con los doce países que pertenecen al clúster 4 del modelo de mezclas gaussianas, lo que refuerza una consistencia entre la diversidad de modelos de clasificación.




Figura 5.21: Gráfico que muestra los doce países con mayor emisión de CO_2 .

A partir de los resultados obtenidos mediante k-means, se observa que Estados Unidos y China son los países que generan mayor “ruido” dentro del proceso de clasificación, resultado coherente con lo identificado por DBSCAN. Este comportamiento se explica por el rol dominante que ambos países desempeñan a nivel económico e industrial. En particular, China tiene una industria manufacturera extensa y dependen del carbón para obtener energía; mientras que EE.UU. emite gran cantidad de emisiones de CO_2 debido al transporte y al consumo energético per cápita elevado.

En la *figura 5.22* se muestra la evolución temporal de las emisiones temporales de China y Estados Unidos. En este gráfico se aprecia que, si bien Estados Unidos mantiene de forma histórica los mayores niveles de emisión durante gran parte del período analizado, China presenta un crecimiento acelerado en las últimas décadas reduciendo la brecha entre ambos países.




Figura 5.22: Gráfico que identifica las emisiones totales de China y Estados Unidos.

Esta conducta se vuelve aún más evidente al analizar las emisiones acumuladas, presentadas en la *figura 5.23*. En este caso, China indica una tendencia exponencial en sus emisiones acumuladas, de modo que si se mantiene este estilo, el país prontamente liderará como emisor global de dióxido de carbono a largo plazo, superando de forma constante a Estados Unidos.




Figura 5.23: Gráfico que muestra las emisiones totales acumuladas de China y Estados Unidos (es decir, a medida que se avanza en los años, se suman las emisiones de cada año).

Por otro lado, el tercer clúster obtenido mediando k-means $k = 4$ agrupa a Alemania, India, Japón y Rusia. La *figura 5.24* presenta las emisiones totales de estos países a lo largo del tiempo, donde se observan trayectorias heterogéneas, pero con niveles de emisión evidentemente menor a los de China y Estados Unidos.




Figura 5.24: Gráfico de las emisiones totales los países que se encuentran en el clúster 3 de k-means $k = 4$.

Además, en la *figura 5.25* (emisiones acumuladas) se aprecia que, si bien estos países contribuyen de manera significativa a las emisiones globales, su crecimiento acumulado es moderado y presenta patrones diferenciados entre economías industrializadas como Alemania y Japón, y economías en vías de desarrollo como India y Rusia.




Figura 5.25: Gráfico de emisiones totales acumuladas los países que se encuentran en el clúster 3 de k-means $k = 4$.

Del mismo modo, se observa que los países que conforman el clúster 4 del método k-means presentan comportamientos heterogéneos en sus trayectorias de emisión. Al observar la *figura 5.26*, estos países no muestran un crecimiento sostenido de las emisiones totales, sino que exhiben variaciones a lo largo del tiempo. Adicionalmente, a partir de la *figura 5.27* se aprecia que las emisiones de los países que pertenecen a este clúster no presentan una progresión “exponencial”, a diferencia de las naciones que se encuentran en los clústeres 2 o 3. En particular, las emisiones totales del clúster 4 no siguen un patrón de crecimiento definido, presentan niveles notablemente menores en comparación a China y muestran una evolución irregular en relación con Japón.




Figura 5.26: Gráfico de emisiones totales los países que se encuentran en el clúster 4 de k-means $k = 4$.

Por último, se destaca que los países del clúster 4 de k-means se comparan explícitamente con China (clúster 2) y Japón (clúster 3), debido a que estos países representan menores emisiones totales dentro de sus respectivos clústeres. Esta comparación permite detallar el comportamiento de los países pertenecientes a los clústeres 1, 2 y 3 del método k-means, evidenciando las diferencias en magnitud y de las emisiones entre los distintos grupos.




Figura 5.27: Gráfico de las emisiones totales de los países que se encuentran en el clúster 4 de k-means $k = 4$, junto con con el gráfico de China (clúster 2) y Japón (clúster 3).

En síntesis, el clúster 1 del método k-means agrupa a los países con mayores niveles históricos de emisión, principalmente China y Estados Unidos, los cuales fueron identificados como “ruido” por el algoritmo DBSCAN. Estos países lideran las emisiones globales de dióxido de carbono. Por otro lado, el clúster 2 reúne a los países que presentan un crecimiento significativo en sus emisiones, pero que no alcanzan a los líderes mencionados. Finalmente, el clúster

3 está compuesto por países cuyas emisiones se mantienen acotadas y no muestran señales de crecimiento acelerado en comparación con los países del primer clúster.

6. Conclusión y Trabajos Futuros

En el presente informe se analizó el comportamiento espacio-temporal de las emisiones de dióxido de carbono (CO_2) a nivel global, considerando datos históricos desde 1950 hasta la actualidad. Mediante la representación funcional de las series temporales con bases B-Spline, se logró capturar de forma consistente la evolución de las emisiones por país.

El Análisis de Componentes Principales Funcionales (FPCA), entregó información estable dadas las componentes de trabajo, dado que la primera componente se vinculó con la magnitud global de las emisiones, mientras que la segunda identificó las divergencias en las tasas de crecimiento y los cambios de tendencia a lo largo de las décadas.

Por otro lado, la aplicación de diversos métodos de clasificación no supervisada, permitió capturar agrupamiento coherente basados en la similitud de las trayectorias. Los diferentes enfoques coinciden en señalar al grupo de países con emisiones históricas como China y Estados Unidos como casos atípicos debido a su volumen extremo, tanto en emisiones anuales como acumuladas. Del mismo modo, se observaron clústeres intermedios, los cuales concuerdan con la evolución de factores económicos, industriales y geográficos.

Cabe señalar que, la convergencia de estos métodos fortalece la validez del estudio. Por ende, la integración de análisis de datos funcionales junto con técnicas de aprendizaje no supervisado constituye una metodología eficiente y fuerte para estudios ambientales complejos, lo cual permite una interpretación profunda en la dinámica de las emisiones globales de CO_2 .

Finalmente como proyección de este trabajo, se sugiere la implementación de un Análisis Funcional de Varianza (fANOVA), el cual permitiría evaluar de forma exhaustiva diferencias interesantes entre grupos de países, sectores emisores o regiones geográficas, considerando la naturaleza continua de estas emisiones. Además, esta herramienta facilitaría la incorporación de variables socioeconómicas, energéticas o demográficas. Lo anterior permitiría fortalecer los resultados obtenidos, sino que avanzar en modelos explicativos que contribuyan a la comprensión y próxima mitigación del cambio climático.

Bibliografía

- Bhatt, H., Davawala, M., Joshi, T., Shah, M., Unnarkat, A., 2023. Forecasting and mitigation of global environmental carbon dioxide emission using machine learning techniques. *Cleaner Chemical Engineering* 5, 100095. URL: <https://www.sciencedirect.com/science/article/pii/S2772782323000037>, doi:<https://doi.org/10.1016/j.clce.2023.100095>.
- Hobbs, J., Katzfuss, M., Nguyen, H., Yadav, V., Liu, J., 2024. Functional analysis of variance (anova) for carbon flux estimates from remote sensing data. *Geoscientific Model Development* 17, 1133–1151. URL: <https://gmd.copernicus.org/articles/17/1133/2024/>, doi:10.5194/gmd-17-1133-2024.
- Mardani, A., Liao, H., Nilashi, M., Alrasheedi, M., Cavallaro, F., 2020. A multi-stage method to predict carbon dioxide emissions using dimensionality reduction, clustering, and machine learning techniques. *Journal of Cleaner Production* 275, 122942. URL: <https://www.sciencedirect.com/science/article/pii/S0959652620329875>, doi:<https://doi.org/10.1016/j.jclepro.2020.122942>.
- Zhang, Z., Schott, J.A., Liu, M., Chen, H., Lu, X., Sumpter, B.G., Fu, J., Dai, S., 2019. Prediction of carbon dioxide adsorption via deep learning. *Angewandte Chemie International Edition* 58, 259–263. URL: <https://onlinelibrary.wiley.com/doi/abs/10.1002/anie.201812363>, doi:<https://doi.org/10.1002/anie.201812363>, arXiv:<https://onlinelibrary.wiley.com/doi/pdf/10.1002/anie.201812363>.

Anexos

Países por cluster usando GM

\$'1'

[1]	"Andorra"	"Anguilla"	"Antarctica"
[4]	"Belize"	"Bermuda"	"Bonaire"
[7]	"British Virgin Islands"	"Burundi"	"Cape Verde"
[10]	"Central African Republic"	"Christmas Island"	"Comoros"
[13]	"Cook Islands"	"Djibouti"	"Dominica"
[16]	"Eritrea"	"Faeroe Islands"	"Micronesia"
[19]	"French Polynesia"	"Gambia"	"Greenland"
[22]	"Grenada"	"Guinea-Bissau"	"Kiribati"
[25]	"Liechtenstein"	"Marshall Islands"	"Montserrat"
[28]	"Nauru"	"Niue"	"Palau"
[31]	"Saint Helena"	"Saint Lucia"	"Samoa"
[34]	"Sao Tome and Principe"	"Seychelles"	"Solomon Islands"
[37]	"Saint Kitts and Nevis"	"Saint Pierre and Miquelon"	"Saint Vincent and the Grenadines"
[40]	"Timor-Leste"	"Tonga"	"Turks and Caicos Islands"
[43]	"Tuvalu"	"Vanuatu"	"Wallis and Futuna"

\$'2'

[1]	"Afghanistan"	"Albania"	"Angola"
[4]	"Antigua and Barbuda"	"Armenia"	"Aruba"
[7]	"Bahamas"	"Barbados"	"Benin"
[10]	"Bhutan"	"Bosnia and Herzegovina"	"Botswana"
[13]	"Brunei Darussalam"	"Burkina Faso"	"Cambodia"
[16]	"Chad"	"Congo"	"Costa Rica"
[19]	"Côte d'Ivoire"	"Curacao"	"Cyprus"
[22]	"Democratic Republic of the Congo"	"Dominican Republic"	"El Salvador"
[25]	"Equatorial Guinea"	"Ethiopia"	"Fiji"
[28]	"Gabon"	"Georgia"	"Ghana"
[31]	"Guatemala"	"Guinea"	"Guyana"

[34]	"Haiti"	"Honduras"	"Iceland"
[37]	"Jamaica"	"Jordan"	"Kenya"
[40]	"Kosovo"	"Laos"	"Lebanon"
[43]	"Lesotho"	"Liberia"	"Luxembourg"
[46]	"Macao"	"North Macedonia"	"Madagascar"
[49]	"Malawi"	"Maldives"	"Mali"
[52]	"Malta"	"Mauritania"	"Mauritius"
[55]	"Montenegro"	"Mozambique"	"Myanmar"
[58]	"Namibia"	"Nepal"	"New Caledonia"
[61]	"Nicaragua"	"Niger"	"State of Palestine"
[64]	"Panama"	"Papua New Guinea"	"Paraguay"
[67]	"Bolivia"	"Cameroon"	"South Sudan"
[70]	"Sudan"	"Rwanda"	"Sint Maarten"
[73]	"Senegal"	"Sierra Leone"	"Slovenia"
[76]	"Somalia"	"Sri Lanka"	"Suriname"
[79]	"Eswatini"	"Tajikistan"	"Togo"
[82]	"Tunisia"	"Uganda"	"Tanzania"
[85]	"Uruguay"	"Yemen"	"Zambia"
[88]	"Zimbabwe"		

\$'3'

[1]	"Algeria"	"Argentina"	"Australia"	"Austria"
[5]	"Azerbaijan"	"Bahrain"	"Bangladesh"	"Belarus"
[9]	"Belgium"	"Brazil"	"Bulgaria"	"Chile"
[13]	"Colombia"	"Croatia"	"Cuba"	"Czech Republic"
[17]	"North Korea"	"Denmark"	"Ecuador"	"Egypt"
[21]	"Estonia"	"Finland"	"Greece"	"Hong Kong"
[25]	"Hungary"	"Indonesia"	"Iraq"	"Ireland"
[29]	"Iran"	"Israel"	"Kazakhstan"	"Kuwait"
[33]	"Kyrgyzstan"	"Latvia"	"Libya"	"Lithuania"
[37]	"Malaysia"	"Mexico"	"Mongolia"	"Morocco"
[41]	"Netherlands"	"New Zealand"	"Nigeria"	"Norway"
[45]	"Oman"	"Pakistan"	"Peru"	"Philippines"
[49]	"Portugal"	"Qatar"	"South Korea"	"Moldova"
[53]	"Romania"	"Saudi Arabia"	"Serbia"	"Singapore"
[57]	"Slovakia"	"South Africa"	"Spain"	"Sweden"
[61]	"Switzerland"	"Syria"	"Taiwan"	"Thailand"
[65]	"Trinidad and Tobago"	"Türkiye"	"Turkmenistan"	"United Kingdom"
[69]	"Uzbekistan"	"Venezuela"	"Viet Nam"	"International Aviation"
[73]	"International Aviation"			

\$'4'

[1]	"Canada"	"China"	"France"	"Germany"	"India"
	"Italy"	"Japan"	"Poland"	"Russia"	"Ukraine"

"United Kingdom" "USA"

Países por cluster usando k-means

k=2

=====

>>> CLUSTER 1 - Total de países: 216

=====

Afghanistan, Albania, Algeria, Andorra, Angola, Anguilla, Antarctica, Antigua and Barbuda, Argentina, Armenia, Aruba, Australia, Austria, Azerbaijan, Bahamas, Bahrain, Bangladesh, Barbados, Belarus, Belgium, Belize, Benin, Bermuda, Bhutan, Bonaire, Bosnia and Herzegovina, Botswana, Brazil, British Virgin Islands, Brunei Darussalam, Bulgaria, Burkina Faso, Burundi, Cambodia, Canada, Cape Verde, Central African Republic, Chad, Chile, Christmas Island, Colombia, Comoros, Congo, Cook Islands, Costa Rica, Côte d'Ivoire, Croatia, Cuba, Curacao, Cyprus, Czechia, North Korea, Democratic Republic of the Congo, Denmark, Djibouti, Dominica, Dominican Republic, Ecuador, Egypt, El Salvador, Equatorial Guinea, Eritrea, Estonia, Ethiopia, Faeroe Islands, Micronesia (Federated States of), Fiji, Finland, France, French Polynesia, Gabon, Gambia, Georgia, Germany, Ghana, Greece, Greenland, Grenada, Guatemala, Guinea, Guinea-Bissau, Guyana, Haiti, Honduras, Hong Kong, Hungary, Iceland, India, Indonesia, Iraq, Ireland, Iran, Israel, Italy, Jamaica, Japan, Jordan, Kazakhstan, Kenya, Kiribati, Kosovo, Kuwait, Kyrgyzstan, Laos, Latvia, Lebanon, Lesotho, Liberia, Libya, Liechtenstein, Lithuania, Luxembourg, Macao, North Macedonia, Madagascar, Malawi, Malaysia, Maldives, Mali, Malta, Marshall Islands, Mauritania, Mauritius, Mexico, Mongolia, Montenegro, Montserrat, Morocco, Mozambique, Myanmar, Namibia, Nauru, Nepal, Netherlands, New Caledonia, New Zealand, Nicaragua, Niger, Nigeria, Niue, Norway, State of Palestine, Oman, Pakistan, Palau, Panama, Papua New Guinea, Paraguay, Peru, Philippines, Bolivia, Poland, Portugal, Qatar, Cameroon, South Korea, Moldova, South Sudan, Sudan, Romania, Russia, Rwanda, Saint Helena, Saint Lucia, Sint Maarten (Dutch part), Samoa, Sao Tome and Principe, Saudi Arabia, Senegal, Serbia, Seychelles, Sierra Leone, Singapore, Slovakia, Slovenia, Solomon Islands, Somalia, South Africa, Spain, Sri Lanka, Saint Kitts and Nevis, Saint Pierre and Miquelon, Saint Vincent and the Grenadines, Suriname, Eswatini, Sweden, Switzerland, Syria, Taiwan, Tajikistan, Thailand, Timor-Leste, Togo, Tonga, Trinidad and Tobago, Tunisia, Türkiye, Turkmenistan, Turks and Caicos Islands, Tuvalu, Uganda, Ukraine, United Arab Emirates, United Kingdom, Tanzania, Uruguay, Uzbekistan, Vanuatu, Venezuela, Viet Nam, Wallis and Futuna Islands, Yemen, Zambia,

Zimbabwe, International Shipping, International Aviation

=====

>>> CLUSTER 2 - Total de países: 2

=====

China, USA

k=4

=====

>>> CLUSTER 1 - Total de países: 193

=====

Afghanistan, Albania, Algeria, Andorra, Angola, Anguilla, Antarctica, Antigua and Barbuda, Argentina, Armenia, Aruba, Austria, Azerbaijan, Bahamas, Bahrain, Bangladesh, Barbados, Belarus, Belgium, Belize, Benin, Bermuda, Bhutan, Bonaire, Bosnia and Herzegovina, Botswana, British Virgin Islands, Brunei Darussalam, Bulgaria, Burkina Faso, Burundi, Cambodia, Cape Verde, Central African Republic, Chad, Chile, Christmas Island, Colombia, Comoros, Congo, Cook Islands, Costa Rica, Côte d'Ivoire, Croatia, Cuba, Curacao, Cyprus, Czechia, North Korea, Democratic Republic of the Congo, Denmark, Djibouti, Dominica, Dominican Republic, Ecuador, Egypt, El Salvador, Equatorial Guinea, Eritrea, Estonia, Ethiopia, Faeroe Islands, Micronesia (Federated States of), Fiji, Finland, French Polynesia, Gabon, Gambia, Georgia, Ghana, Greece, Greenland, Grenada, Guatemala, Guinea, Guinea-Bissau, Guyana, Haiti, Honduras, Hong Kong, Hungary, Iceland, Iraq, Ireland, Israel, Jamaica, Jordan, Kenya, Kiribati, Kosovo, Kuwait, Kyrgyzstan, Laos, Latvia, Lebanon, Lesotho, Liberia, Libya, Liechtenstein, Lithuania, Luxembourg, Macao, North Macedonia, Madagascar, Malawi, Malaysia, Maldives, Mali, Malta, Marshall Islands, Mauritania, Mauritius, Mongolia, Montenegro, Montserrat, Morocco, Mozambique, Myanmar, Namibia, Nauru, Nepal, Netherlands, New Caledonia, New Zealand, Nicaragua, Niger, Nigeria, Niue, Norway, State of Palestine, Oman, Pakistan, Palau, Panama, Papua New Guinea, Paraguay, Peru, Philippines, Bolivia, Portugal, Qatar, Cameroon, Moldova, South Sudan, Sudan, Romania, Rwanda, Saint Helena, Saint Lucia, Sint Maarten (Dutch part), Samoa, Sao Tome and Principe, Senegal, Serbia, Seychelles, Sierra Leone, Singapore, Slovakia, Slovenia, Solomon Islands, Somalia, Sri Lanka, Saint Kitts and Nevis, Saint Pierre and Miquelon, Saint Vincent and the Grenadines, Suriname, Eswatini, Sweden, Switzerland, Syria, Taiwan, Tajikistan, Thailand, Timor-Leste, Togo, Tonga, Trinidad and Tobago, Tunisia, Turkmenistan, Turks and Caicos Islands,

Tuvalu, Uganda, United Arab Emirates, Tanzania, Uruguay, Uzbekistan, Vanuatu, Venezuela, Viet Nam, Wallis and Futuna Islands, Yemen, Zambia, Zimbabwe

```
=====
>>> CLUSTER 2 - Total de países: 2
```

```
=====
China, USA
```

```
=====
>>> CLUSTER 3 - Total de países: 4
```

```
=====
Germany, India, Japan, Russia
```

```
=====
>>> CLUSTER 4 - Total de países: 19
```

```
=====
Australia, Brazil, Canada, France, Indonesia, Iran, Italy, Kazakhstan,
Mexico, Poland, South Korea, Saudi Arabia, South Africa, Spain, Türkiye,
Ukraine, United Kingdom, International Shipping, International Aviation
```

Códigos ocupados en R

```
library(fda)           # Para representacion Funcional
library(dplyr)         # Para manipulación de datos
library(readr)         # Para leer archivos CSV (en lugar de readxl)
library(tidyr)         # Para pivotar los datos (pivot_wider)
library(stringr)       # Para limpiar nombres de países
library(ggplot2)       # Para gráficos avanzados de clustering
library(mclust)        # Para clustering avanzado
```

```
head.matrix(huella_carbono_PowerQuery)
```

```
# Limpieza datos
datos_filtrados <- huella_carbono_PowerQuery %>%
```

```

mutate(Country = str_trim(str_replace_all(Country, "\\n", ""))) %>%
# Nos quedamos con filas que SÍ tienen un código ISO y NO son "Global"
filter(!is.na('ISO 3166-1 alpha-3'), Country != "Global")

# Pivotear datos
datos_wide <- datos_filtrados %>%
  pivot_wider(
    id_cols = "Year",          # Las filas serán los años
    names_from = "Country",    # Las columnas serán los países
    values_from = "Total"      # Los valores que analizaremos
  )

# Reemplazar NA con 0
datos_wide[is.na(datos_wide)] <- 0

# VARIABLES
#tiempo <- datos_wide$Year
#tiempo

datos_limpios <- datos_wide %>%
  filter(Year >= 1950, Year <= 2024) # Filtramos solo los años válidos

tiempo_0 <- datos_limpios$Year
tiempo_0
print(paste("Clase de dato 'tiempo':", class(tiempo_0)))

#str(datos_limpios[, -1])

# Nuestras 'variables' (curvas). Cada COLUMNA es ahora un país, y se convertirán los
datos_numericos <- datos_limpios %>%
  mutate(across(-Year, ~ {
    # Si es una lista, toma el primer valor numérico
    if (is.list(.x)) sapply(.x, function(v) as.numeric(v[1]))
    else as.numeric(.x)
  }))

# Verificar si hubo NAs introducidos
sum(is.na(datos_numericos))

```

```
# Crear matriz numérica final
variables_matriz <- as.matrix(datos_numericos[, -1])
variables_matriz

#variables_matriz_log <- log(variables_matriz + 1) # CAMBIAR A log(...) si los datos e

print(paste("Clase de variables:", class(variables_matriz)))

# Guardamos los nombres de los países para el final
nombres_paises <- colnames(variables_matriz)
nombres_paises

# Asegurarnos que es numérico
storage.mode(variables_matriz) <- "double"
print(paste("Dimensiones de variables_matriz:", paste(dim(variables_matriz), collapse
print(paste("Clase de variables_matriz:", class(variables_matriz)))

# Guardamos los nombres de país correctamente
nombres_paises <- colnames(variables_matriz)
length(nombres_paises)

summary(is.finite(as.matrix(variables_matriz)))
sum(!is.finite(as.matrix(variables_matriz)))
variables_matriz[!is.finite(variables_matriz)] <- 0 #NA, NaN o Inf en la matriz. Se de

variables_matriz <- apply(variables_matriz, 2, function(col) {
  col[!is.finite(col)] <- mean(col[is.finite(col)], na.rm = TRUE)
  col
})

# VISUALIZACIÓN GENERAL
```

```

# muestra de 30 países.
#set.seed(123)
indices_muestra <- sample(ncol(variables_matriz), 30)
indices_muestra

#GRÁFICO EN BRUTO
matplot(tiempo_0, variables_matriz[, indices_muestra], type = "l", lty = 1, lwd = 1.2,
        col = rainbow(length(indices_muestra)),
        xlab = "Año", ylab = "Emisiones Totales",
        main = "Curvas de Emisión (Muestra de 30 países aleatorios)")

# TOMEMOS 10 PAISES

indices_muestra_1 <- sample(ncol(variables_matriz), 10)
indices_muestra_1
matplot(tiempo_0, variables_matriz[, indices_muestra_1], type = "l", lty = 1, lwd = 1.2,
        col = rainbow(length(indices_muestra_1)),
        xlab = "Año", ylab = "Emisiones Totales",
        main = "Curvas de Emisión (Muestra de 10 países aleatorios)")

# TOMEMOS 5 PAISES

indices_muestra_2 <- sample(ncol(variables_matriz), 5)
indices_muestra_2
matplot(tiempo_0, variables_matriz[, indices_muestra_2], type = "l", lty = 1, lwd = 1.2,
        col = rainbow(length(indices_muestra_2)),
        xlab = "Año", ylab = "Emisiones Totales",
        main = "Curvas de Emisión (Muestra de 5 países aleatorios)")

# TOMEMOS 1 PAIS

indices_muestra_3 <- sample(ncol(variables_matriz), 1)
indices_muestra_3

nombre_pais <- nombres_paises[indices_muestra_3]

matplot(tiempo_0, variables_matriz[, indices_muestra_3], type = "l", lty = 1, lwd = 1.2,
        col = rainbow(length(indices_muestra_3)),
        xlab = "Año", ylab = "Emisiones Totales",
        main = paste("Curva de Emisión de:", nombre_pais))

#####

```

```
#####
#####
#####
#####
#####
```

```
#####
#####
#####
#####
#####
#####
```

```
# =====
# Análisis FDA
# =====
```

```
# actualización variables para el FDA
tiempo <- tiempo_0
```

```
variables <- variables_matriz # ----- ANÁLISIS SIN LOGARITMOS
nombres_paises <- colnames(variables) # Guardamos los nombres para el clustering
```

```
#is.numeric(variables)
```

```
# Creación de la base B-SPLINE y FOURIER
```

```
# número de bases B-spline --- 30
# número de bases Fourier --- 30
rango_tiempo <- c(min(tiempo), max(tiempo))
nbasis_sugerido <- 30 # PROBAR CON 30
```

```
# B-spline
base.bspline <- create.bspline.basis(rangeval = rango_tiempo, nbasis = nbasis_sugerido)
```

```
# Fourier
base.fourier <- create.fourier.basis(rangeval = rango_tiempo, nbasis = nbasis_sugerido)
```



```
# Exponencial
#tasas_crecimiento <- seq(0, 0.05, length.out = nbasis_sugerido)
#base.exponencial <- create.exponential.basis(rangeval = rango_tiempo, ratevec = tasas)

# polygonal
#base.polygonal <- create.polygonal.basis(rangeval = rango_tiempo, argvals = tiempo)

# Ajustar coeficientes en las bases funcionales
repre.bspline <- Data2fd(argvals = tiempo, y = variables, basisobj = base.bspline)

repre.fourier <- Data2fd(argvals = tiempo, y = variables, basisobj = base.fourier)

#repre.polygonal <- Data2fd(argvals = tiempo, y = variables, basisobj = base.polygonal)

# Gráficas
par(mfrow = c(1, 2), mar = c(4, 4, 2, 1))
plot(repre.bspline, main = "Gráfica B-Spline",
      xlab = "Año", ylab = "Emisiones")
plot(repre.fourier, main = "Gráfica Fourier",
      xlab = "Año", ylab = "Emisiones")

# Es mejor B-spline que Fourier debido a que los datos no muestran periodicidad
# Idea: probar con otras bases, o cambiar el número de bases B-spline

# Evaluación del Error (MSE)
y_pred_bspline <- eval.fd(tiempo, repre.bspline)
mse_bspline <- mean((variables - y_pred_bspline)^2)

y_pred_fourier <- eval.fd(tiempo, repre.fourier)
mse_fourier <- mean((variables - y_pred_fourier)^2)

cat("MSE B-Spline:", mse_bspline, "\n")
cat("MSE Fourier:", mse_fourier, "\n")
#cat("MSE polygonal:", mse_polygonal, "\n")
```

```
# B-Spline tiene un MSE mucho menor

# Media y Varianza Funcional (B-SPLINE)

# Nos enfocaremos en B-Spline

mean_fd <- mean.fd(repre.bspline)

var_fd <- var.fd(repre.bspline)

# Gráfico de curvas, media y varianza
grid_time <- seq(min(tiempo), max(tiempo), length.out = 200)
fd_values_bspline <- eval.fd(grid_time, repre.bspline)
mean_values_bspline <- eval.fd(grid_time, mean_fd)
cov_bspline <- eval.bifd(grid_time, grid_time, var_fd)
var_values_bspline <- diag(cov_bspline)

par(mfrow = c(1,1))
matplot(grid_time, fd_values_bspline, type = "l", lty = 1, col = "lightgray",
        xlab = "Año", ylab = "Log(Emisiones)",
        main = "B-Spline: Curvas de Países, Media y Varianza")
lines(grid_time, mean_values_bspline, col = "blue", lwd = 3)
lines(grid_time, mean_values_bspline + sqrt(var_values_bspline), col = "red", lwd = 2)
lines(grid_time, mean_values_bspline - sqrt(var_values_bspline), col = "red", lwd = 2)
legend("topleft", legend = c("Países", "Media", "Media  $\pm$  1 SD"),
      col = c("lightgray", "blue", "red"), lty = c(1,1,2), lwd = c(1,3,2))

# Para visualizar mejor los datos, puedo escalar 'variables' usando la función log(...)

# Análisis de Componentes Principales Funcionales (FPCA)

# Usamos B-Spline
nharm_max <- nbasis_sugerido - 1
fpca_bspline <- pca.fd(repre.bspline, nharm = nharm_max)
```

```
# Varianza acumulada
cumvar_bspline <- cumsum(fpca_bspline$varprop)
k95_bspline <- which(cumvar_bspline >= 0.95)[1]

cat("B-Spline necesita", k95_bspline, "componentes para 95% de varianza\n")

# Graficar autofunciones - CON DOS O 3 COMPONENTES DEBERÍA SER SUFICIENTE
#
par(mfrow = c(2,2), mar = c(4,4,2,1))
plot.pca.fd(fpca_bspline, harm = 1, nx = 200, lwd = 2, col = "blue")
#title("B-Spline - Autofunción CP1")
plot.pca.fd(fpca_bspline, harm = 2, nx = 200, lwd = 2, col = "red")
#title("B-Spline - Autofunción CP2")

# Clustering Funcional (mclust) ---- Gaussian mixture model clustering

# Usaremos los scores de los 2 primeros componentes si no se usa el logaritmo
scores_bspline <- fpca_bspline$scores[, 1:2]
colnames(scores_bspline) <- c("CP1", "CP2")

# Ajustar modelo de clustering
mclust_result <- Mclust(scores_bspline, G = 2:6) # Buscamos de 2 a 6 clusters
summary(mclust_result) # Ver el número óptimo de clusters (G)

# Graficar los clusters en el espacio CP1-CP2
plot(mclust_result, what = "classification",
     main = "Clusters de Países (mclust)")

# Obtener el número de clusters óptimo encontrado
G_optimo <- mclust_result$G

# leyenda
legend("topleft", # Posición (puedes cambiar a "topright")
```

```

    legend = paste("Cluster", 1:G_optimo),          # Texto: "Cluster 1", "Cluster 2".
    col = mclust.options("classPlotColors")[1:G_optimo], # Mismos colores que mclus
    pch = mclust.options("classPlotSymbols")[1:G_optimo], # Mismos símbolos que mclu
    title = "Leyenda",
    bg = "white",                                     # Fondo blanco para que se lea bie
    cex = 0.8)                                         # Tamaño del texto

# Visualización Final: Curvas por Cluster
cluster_asignado <- mclust_result$classification

# Crear un dataframe para ver qué país quedó en qué cluster
df_clusters_paises <- data.frame(
  Pais = nombres_paises,
  Cluster = cluster_asignado,
  Score_CP1 = scores_bspline[, "CP1"],
  Score_CP2 = scores_bspline[, "CP2"]
)

# Ver los países de cada cluster
print("Países por cluster:")
print(split(df_clusters_paises$Pais, df_clusters_paises$Cluster))

# Graficar las curvas originales coloreadas por el cluster
par(mfrow = c(1,1))
matplot(grid_time, fd_values_bspline, type = "l", lty = 1,
        col = cluster_asignado, lwd = 1.5,
        xlab = "Año", ylab = "Log(Emissiones)",
        main = "Curvas de Emisión Coloreadas por Clúster (mclust)")

# Agregar la media funcional de cada clúster
for (k in 1:mclust_result$G) {
  mean_cluster <- mean.fd(repre.bspline[cluster_asignado == k])
  lines(grid_time, eval.fd(grid_time, mean_cluster),
        col = k, lwd = 4, lty = 2)
}
legend("topleft", legend = c(paste("Clúster", 1:mclust_result$G), "Medias"),
      col = c(1:mclust_result$G, 1), lty = c(rep(1, mclust_result$G), 2),
      lwd = c(rep(1.5, mclust_result$G), 4))

# Gráficas separadas por clúster

```

```

#mclust_result$G

# Definimos colores base
colores_clusters <- rainbow(mclust_result$G)

# Creamos una figura por clúster
for (k in 1:mclust_result$G) {
  indices_cluster <- which(cluster_asignado == k)

  # Subconjunto de curvas y cálculo de la media funcional del clúster
  fd_cluster <- repre.bspline[indices_cluster]
  curvas_cluster <- eval.fd(grid_time, fd_cluster)
  mean_cluster <- mean.fd(fd_cluster)
  mean_values <- eval.fd(grid_time, mean_cluster)

  # Gráfico del clúster k
  par(mfrow = c(1,1))
  matplot(grid_time, curvas_cluster, type = "l", lty = 1,
          col = adjustcolor(colores_clusters[k], alpha.f = 0.4),
          xlab = "Año", ylab = "Log(Emisiones)",
          main = paste("Curvas de Emisión - Clúster", k))

  # Agregamos la curva media
  lines(grid_time, mean_values, col = colores_clusters[k], lwd = 3)

  # Agregamos leyenda con los nombres de los países en el clúster
  legend("topleft",
        legend = c(paste("Clúster", k, "(", length(indices_cluster), "países)"),
                  "Media funcional"),
        col = c(adjustcolor(colores_clusters[k], alpha.f = 0.4), colores_clusters[k]),
        lty = c(1,1), lwd = c(1,3))

  # Mostrar nombres de países del cluster en consola
  cat("\n===== \n")
  cat("Cluster", k, "contiene los países: \n")
  cat(paste(df_clusters_países$País[indices_cluster], collapse = ", "), "\n")
  cat("===== \n")
}

# ---- k-means -- #

# si no se ocupa el logaritmo

```

```
scores_bspline <- fpca_bspline$scores[, 1:2]
colnames(scores_bspline) <- c("CP1", "CP2")

# NUMERO OPTIMO CLUSTERS
set.seed(123)
wss <- numeric(10) # Vector para guardar la "Suma de Cuadrados Intra-cluster"

for (k in 1:10) {
  wss[k] <- kmeans(scores_bspline, centers = k, nstart = 25)$tot.withinss
}

# Graficamos el codo: k óptimo se encuentra cuando la línea deja de bajar bruscamente
par(mfrow = c(1,1))
plot(1:10, wss, type = "b", pch = 19, col = "blue",
     xlab = "Número de Clusters (k)",
     ylab = "WSS (Error Intra-cluster)",
     main = "Método del Codo")

# k-optimo.... ¿se puede cambiar?
k_optimo <- 4

set.seed(123)
kmeans_result <- kmeans(scores_bspline,
                        centers = k_optimo,
                        iter.max = 50,
                        nstart = 25,
                        algorithm = "Hartigan-Wong")

# Resumen estadístico real de kmeans
print(kmeans_result)

# Guardar el cluster en un dataframe
df_scores <- data.frame(
  Pais = nombres_paises,
  CP1 = scores_bspline[, 1],
  CP2 = scores_bspline[, 2],
  Cluster = as.factor(kmeans_result$cluster) # Convertir a factor para colores
)

# GRAFICAR CLUSTERS
```

```

# Centroides (sin logaritmo)
centros <- as.data.frame(kmeans_result$centers)
colnames(centros) <- c("CP1", "CP2")

centros$Cluster <- as.factor(1:k_optimo)

ggplot(df_scores, aes(x = CP1, y = CP2, color = Cluster)) +
  # Los puntos (países)
  geom_point(alpha = 0.6, size = 2) +
  # Los centroides (X negras grandes)
  geom_point(data = centros, aes(x = CP1, y = CP2),
             shape = 3, size = 5, stroke = 2, color = "black") +
  # Elipses (Forma del grupo)
  stat_ellipse(type = "t", level = 0.95, linetype = 2) +
  labs(title = paste("K-Means Clustering (k =", k_optimo, ")"),
       subtitle = "Agrupación según patrones de emisión (CP1 y CP2)",
       x = "Componente Principal 1",
       y = "Componente Principal 2") +
  theme_minimal()

# GRAFICAR CURVAS DE CADA CLUSTER

# ¿qué significa cada grupo?
colores <- c("red", "blue", "green3", "orange", "purple")[1:k_optimo]

dev.new(width = 12, height = 6) # Abre una ventana nueva de 12x6 pulgadas
par(mfrow = c(1, k_optimo), mar = c(2, 2, 3, 1))

# GRAFICO POR CADA CLUSTER
for (i in 1:k_optimo) {
  indices <- which(kmeans_result$cluster == i)

  # Graficamos
  matplot(tiempo, variables[, indices], type = "l", lty = 1,
          col = adjustcolor(colores[i], alpha.f = 0.2),
          xlab = "", ylab = "", # Quitamos etiquetas ejes para ahorrar espacio
          main = paste("Cluster", i, "(", length(indices), "Países)"),

```

```

        ylim = range(variables))

# Agregamos la media
media_cluster <- mean.fد(represpline[indices])
lines(media_cluster, col = "black", lwd = 3)

# Países por cluster
cat("\n\n=====\\n")
cat(paste(">>> CLUSTER", i, "- Total de países:", length(indices), "\\n"))
cat("=====\\n")

nombres_cluster <- nombres_paises[indices]
cat(paste(nombres_cluster, collapse = ", "))
cat("\\n")

}
##### FIN CLUSTER K-MEANS

# -- DBSCAN -- #
library(dbscan)

# PREPARAR DATOS --- scores del FPCA (CP1 y CP2)

# Si no se ocupa el logaritmo
scores_dbscan <- fpca_spline$scores[, 1:2]
colnames(scores_dbscan) <- c("CP1", "CP2")

# 'EPS' ÓPTIMO (k-NN Distance Plot)

# DBSCAN necesita dos parámetros:
# 1. minPts: Cuántos puntos mínimos hacen un "barrio denso".
#   Regla general: dimensiones + 1. Aquí tenemos 2 dim, así que minPts = 3 o 4.
#   Usaremos minPts = 4.

# 2. eps: El radio de ese barrio.

# Graficamos la distancia a los vecinos más cercanos para encontrar el "codo"
par(mfrow = c(1,1))

```



```
kNNdistplot(scores_dbscan, k = 4)
```

```
#punto donde la curva se dispara verticalmente (el "codo").
abline(h = 20, col = "red", lty = 3)
```

```
# Define tu eps basado en el gráfico anterior
mi_eps <- 10000000000 # <--- ¡CAMBIA ESTE VALOR SEGÚN TU GRÁFICO kNN!
mi_minPts <- 20
```

```
# EJECUTAR DBSCAN
set.seed(123)
dbscan_result <- dbscan(scores_dbscan, eps = mi_eps, minPts = mi_minPts)
```

```
# Ver resultados
print(dbscan_result)
```

```
# NOTA IMPORTANTE:
# - El Cluster '0' no es un grupo real. Son los OUTLIERS (Ruido).
# - Los Clusters 1, 2, etc. son los grupos densos encontrados.
```

```
# Guardar resultados en dataframe
df_dbscan <- data.frame(
  Pais = nombres_paises,
  CP1 = scores_dbscan[, 1],
  CP2 = scores_dbscan[, 2],
  Cluster = as.factor(dbscan_result$cluster)
)
```

```
# GRAFICAR SCORES (VISUALIZACIÓN DE DENSIDAD)
```

```
ggplot(df_dbscan, aes(x = CP1, y = CP2, color = Cluster, label = Pais)) +
  geom_point(size = 2, alpha = 0.7) +
  # Usamos 'hullplot' conceptualmente con ggplot:
  # El Cluster 0 (Ruido) lo pintamos de negro o gris para destacar que son atípicos
  scale_color_manual(values = c("0" = "black", "1" = "red", "2" = "green3", "3" = "blue"),
  labs(title = paste("DBSCAN Clustering (eps =", mi_eps, ", minPts =", mi_minPts, ")"),
        subtitle = "Cluster 0 = Ruido / Outliers (Países con comportamiento único)",
        x = "Score CP1", y = "Score CP2",
        color = "Cluster (0=Ruido)") +
  theme_minimal()
```

```

# VER QUÉ PAÍSES SON "RUIDO" (Cluster 0)
cat("\n--- PAÍSES DETECTADOS COMO OUTLIERS (RUIDO) ---\n")
outliers <- df_dbscan$Pais[df_dbscan$Cluster == 0]
print(paste(outliers, collapse = ", "))

# GRAFICAR CURVAS POR GRUPO (Separando Ruido de Grupos)

# Obtenemos los clusters únicos encontrados (incluyendo el 0)
grupos_encontrados <- sort(unique(dbscan_result$cluster))

par(mfrow = c(1, length(grupos_encontrados)), mar = c(2,2,3,1))

for (g in grupos_encontrados) {
  indices <- which(dbscan_result$cluster == g)

  # Título especial para el grupo 0
  titulo <- if(g == 0) paste("RUIDO / OUTLIERS (", length(indices), ")") else paste("C")
  color_grupo <- if(g == 0) "black" else rainbow(length(grupos_encontrados)-1)[g]

  # Graficar curvas
  matplot(tiempo, variables[, indices], type = "l", lty = 1,
          col = adjustcolor(color_grupo, alpha.f = 0.3),
          xlab = "", ylab = "",
          main = titulo,
          ylim = range(variables))

  # Solo dibujamos la media si NO es el grupo de ruido (el promedio de ruido no tiene
  if (g != 0) {
    media_g <- mean.fد(repre.bspline[indices])
    lines(media_g, col = "black", lwd = 3)
  }
}
par(mfrow=c(1,1)) # Reset

# -- ST-DBSCAN -- #
library(rnaturalearth)
library(rnaturalearthdata)
library(sf)

# OBTENER COORDENADAS GEOGRÁFICAS (LAT/LON)

```

```

# Descargamos los datos del mundo
mundo <- ne_countries(scale = "medium", returnclass = "sf")

# Vamos a extraer los ISOs únicos que estamos usando en el análisis.
isos_analisis <- datos_filtrados %>%
  select(Country, 'ISO 3166-1 alpha-3') %>%
  distinct()

# Cruzamos con el mapa para obtener latitud y longitud del centroide de cada país
datos_geo <- mundo %>%
  select(iso_a3, geometry) %>%
  # Calculamos el centroide (el punto medio del país)
  mutate(
    lon = sf::st_coordinates(sf::st_centroid(geometry))[,1],
    lat = sf::st_coordinates(sf::st_centroid(geometry))[,2]
  ) %>%
  as.data.frame() %>%
  select(iso_a3, lon, lat)

# Unimos las coordenadas con tus datos del FPCA
df_fpca <- data.frame(
  Pais = nombres_paises,
  CP1 = scores_bspline[, 1],
  CP2 = scores_bspline[, 2]
)

# Hacemos el join usando el nombre del país o necesitamos el ISO en df_fpca
df_fpca <- df_fpca %>%
  left_join(isos_analisis, by = c("Pais" = "Country")) %>%
  left_join(datos_geo, by = c("ISO 3166-1 alpha-3" = "iso_a3"))

# Limpieza: Eliminar países que no encontraron coordenadas (si los hay)
df_st <- na.omit(df_fpca)

print(head(df_st))

# PREPARAR LA MATRIZ ESPACIO-TEMPORAL

# Aquí está el truco del ST-DBSCAN.
# Creamos una matriz con 4 dimensiones: CP1, CP2 (Tiempo/Forma) y Lat, Lon (Espacio).

```

```
matriz_st <- df_st %>% select(CP1, CP2, lon, lat)

# IMPORTANTE: ESCALADO (Scaling)
# Las coordenadas van de -180 a 180. Los Scores pueden ir de -500 a 500.
# Si no escalamos, la dimensión más grande dominará el clustering.
# scale() pone todo en unidades de "desviaciones estándar".

matriz_st_scaled <- scale(matriz_st)

# ENCONTRAR EPS ÓPTIMO (kNN Dist Plot)

par(mfrow = c(1,1))
kNNdistplot(matriz_st_scaled, k = 5)
abline(h = 1.5, col = "red", lty = 2) # Línea de referencia (ajusta según lo que veas)

# Mira el gráfico. Donde la curva sube rápido es tu epsilon.
# Supongamos que es 1.5 (al estar escalado, eps suele estar entre 0.5 y 2.0)
eps_st <- 1.5
minPts_st <- 5

# EJECUTAR ST-DBSCAN
set.seed(123)
st_dbscan_res <- dbscan(matriz_st_scaled, eps = eps_st, minPts = minPts_st)

print(st_dbscan_res)

# Guardamos el cluster en el dataframe
df_st$ClusterST <- as.factor(st_dbscan_res$cluster)

# VISUALIZACIÓN EN UN MAPA MUNDIAL

# Cargamos el mapa base de nuevo para ggplot
world_map <- map_data("world")

ggplot() +
  # Dibujar el mapa base en gris claro
  geom_map(data = world_map, map = world_map,
    aes(long, lat, map_id = region),
    fill = "lightgray", color = "white") +
```

```

# Dibujar los puntos de nuestros países coloreados por Cluster ST
geom_point(data = df_st, aes(x = lon, y = lat, color = ClusterST),
           size = 3, alpha = 0.8) +

# Colores (El Cluster 0 es negro/ruido)
scale_color_manual(values = c("0" = "black", "1" = "red", "2" = "blue",
                              "3" = "green", "4" = "orange", "5" = "purple")) +

labs(title = "ST-DBSCAN: Clusters Funcionales y Geográficos",
     subtitle = "Agrupa países por cercanía geográfica Y similitud en emisiones",
     color = "Cluster ST (0=Ruido)") +
theme_minimal()

# COMPARACIÓN

# Veamos las curvas promedio de estos grupos Espacio-Temporales

grupos <- sort(unique(st_dbscan_res$cluster))
colores <- c("black", "red", "blue", "green", "orange", "purple")

par(mfrow = c(1, length(grupos)), mar = c(2,2,3,1))

for (g in grupos) {
  # Filtramos nombres de países en este grupo
  paises_grupo <- df_st$Pais[df_st$ClusterST == g]

  # Encontramos los índices en la matriz original 'variables'
  indices <- which(nombres_paises %in% paises_grupo)

  if(length(indices) > 0) {
    titulo <- if(g==0) "Ruido / Dispersos" else paste("Cluster ST", g)

    matplot(tiempo, variables[, indices], type = "l", lty = 1,
            col = adjustcolor(colores[g+1], alpha.f = 0.4),
            main = titulo, ylim = range(variables), ylab="", xlab="")

    # Media (solo si no es ruido)
    if(g != 0) {
      media <- mean.fd(repre.bspline[indices])
      lines(media, col = "black", lwd = 3)
    }
  }
}

```

```

}

# OBTENER COORDENADAS GEOGRÁFICAS (LAT/LON)
# Descargamos los datos del mundo
mundo <- ne_countries(scale = "medium", returnclass = "sf")

# Tu dataset original 'datos_filtrados' tiene la columna "ISO 3166-1 alpha-3".
# Vamos a extraer los ISOs únicos que estamos usando en el análisis.
isos_analisis <- datos_filtrados %>%
  select(Country, 'ISO 3166-1 alpha-3') %>%
  distinct()

# Cruzamos con el mapa para obtener latitud y longitud del centroide de cada país
datos_geo <- mundo %>%
  select(iso_a3, geometry) %>%
  # Calculamos el centroide (el punto medio del país)
  mutate(
    lon = sf::st_coordinates(sf::st_centroid(geometry))[,1],
    lat = sf::st_coordinates(sf::st_centroid(geometry))[,2]
  ) %>%
  as.data.frame() %>%
  select(iso_a3, lon, lat)

# Unimos las coordenadas con tus datos del FPCA
# Asumimos que 'nombres_paises' está en el mismo orden que 'scores_bspline'
df_fpca <- data.frame(
  Pais = nombres_paises,
  CP1 = scores_bspline[, 1],
  CP2 = scores_bspline[, 2]
)

# Hacemos el join usando el nombre del país o necesitamos el ISO en df_fpca
# Para hacerlo robusto, recuperemos el ISO de tus datos originales asociados a 'nombre'
df_fpca <- df_fpca %>%
  left_join(isos_analisis, by = c("Pais" = "Country")) %>%
  left_join(datos_geo, by = c("ISO 3166-1 alpha-3" = "iso_a3"))

# Limpieza: Eliminar países que no encontraron coordenadas (si los hay)
df_st <- na.omit(df_fpca)

print(head(df_st))

```

```
# PREPARAR LA MATRIZ ESPACIO-TEMPORAL
# Aquí está el truco del ST-DBSCAN.
# Creamos una matriz con 4 dimensiones: CP1, CP2 (Tiempo/Forma) y Lat, Lon (Espacio).

matriz_st <- df_st %>% select(CP1, CP2, lon, lat)

# IMPORTANTE: ESCALADO (Scaling)
# Las coordenadas van de -180 a 180. Los Scores pueden ir de -500 a 500.
# Si no escalamos, la dimensión más grande dominará el clustering.
# scale() pone todo en unidades de "desviaciones estándar".

matriz_st_scaled <- scale(matriz_st)

# ENCONTRAR EPS ÓPTIMO (kNN Dist Plot)

par(mfrow = c(1,1))
kNNdistplot(matriz_st_scaled, k = 5)
abline(h = 1.5, col = "red", lty = 2) # Línea de referencia (ajusta según lo que veas)

# Mira el gráfico. Donde la curva sube rápido es tu epsilon.
# Supongamos que es 1.5 (al estar escalado, eps suele estar entre 0.5 y 2.0)
eps_st <- 1.5
minPts_st <- 5

# EJECUTAR ST-DBSCAN
set.seed(123)
st_dbscan_res <- dbscan(matriz_st_scaled, eps = eps_st, minPts = minPts_st)

print(st_dbscan_res)

# Guardamos el cluster en el dataframe
df_st$ClusterST <- as.factor(st_dbscan_res$cluster)

# VISUALIZACIÓN EN UN MAPA MUNDIAL
# Esto es lo más valioso: ver los clusters en el mapa.

# Cargamos el mapa base de nuevo para ggplot
world_map <- map_data("world")

# Corregir algunos nombres para que coincidan con el mapa si es necesario
# Pero usaremos las coordenadas (lat/lon) que ya tenemos, así que no importa el nombre
```

```

ggplot() +
  # Dibujar el mapa base en gris claro
  geom_map(data = world_map, map = world_map,
           aes(long, lat, map_id = region),
           fill = "lightgray", color = "white") +

  # Dibujar los puntos de nuestros países coloreados por Cluster ST
  geom_point(data = df_st, aes(x = lon, y = lat, color = ClusterST),
            size = 3, alpha = 0.8) +

  # Colores (El Cluster 0 es negro/ruido)
  scale_color_manual(values = c("0" = "black", "1" = "red", "2" = "blue",
                                "3" = "green", "4" = "orange", "5" = "purple")) +

  labs(title = "ST-DBSCAN: Clusters Funcionales y Geográficos",
       subtitle = "Agrupar países por cercanía geográfica Y similitud en emisiones",
       color = "Cluster ST (0=Ruido)") +
  theme_minimal()

# COMPARACIÓN

# Veamos las curvas promedio de estos grupos Espacio-Temporales

grupos <- sort(unique(st_dbscan_res$cluster))
colores <- c("black", "red", "blue", "green", "orange", "purple")

par(mfrow = c(1, length(grupos)), mar = c(2,2,3,1))

for (g in grupos) {
  # Filtramos nombres de países en este grupo
  paises_grupo <- df_st$Pais[df_st$ClusterST == g]

  # Encontramos los índices en la matriz original 'variables'
  indices <- which(nombres_paises %in% paises_grupo)

  if(length(indices) > 0) {
    titulo <- if(g==0) "Ruido / Dispersos" else paste("Cluster ST", g)

    matplot(tiempo, variables[, indices], type = "l", lty = 1,
            col = adjustcolor(colores[g+1], alpha.f = 0.4),
            main = titulo, ylim = range(variables), ylab="", xlab="")
  }
}

```



```
# Media (solo si no es ruido)
if(g != 0) {
  media <- mean.fd(repre.bspline[indices])
  lines(media, col = "black", lwd = 3)
}
}
```